

参赛学生姓名：____钟熠____

中学：____华东师范大学第二附属中学____

省份：____上海____

国家/地区：____中国____

指导老师姓名：____余晓瑾____

指导老师单位：华东师范大学第二附属中学

标题：____基于 U-Net 架构的路网预测方案____

基于 U-Net 架构的路网预测方案

作者：____钟熠____

摘要

作者提出了一种创新的 U-Net 架构应用，通过 AdamW 优化器和 IoU Loss 与 Focal Loss 的结合应用，本模型可以借助地理空间数据来预测可能的道路网络。该机器学习模型的训练使用了河流网络和住宅区数据，以及 TIFF 格式的高程数据。该模型通过使用带有 `pos_weight` 张量的 Focal Loss，使其对类别不平衡导致的在复杂的城市和农村景观中代表性较少的小型道路及偏远的居民区等信息更加敏感。为了确保在各种环境中的鲁棒性和泛化能力，模型在 60% 的训练集、20% 的验证集和 20% 的测试集上进行了训练和评估。结果显示，尽管该模型当前由于数据源和算力的限制还无法给出完整精确的道路网络，各主干道路的正确预测表明了使用人工智能模型预测道路网络的建设和扩展具有显著潜力。这种方式无疑有助于增强区域连通性，促进各地区经济增长，并有效地支持战略性的智慧城市规划举措。本研究大大推动了道路网络预测技术的发展，并强调了其在通过增强道路网络建设来改善经济和社会基础设施方面的重要性。

关键词—— 道路网络预测, 深度学习, 城市建设, Focal Loss, U-Net

目录

1 引入	5
2 相关研究	5
2.1 深度学习	5
2.1.1 卷积神经网络 (CNN)	6
2.1.2 U-Net 架构	6
2.1.3 AdamW 优化器	7
2.1.4 Focal Loss	7
2.2 相关应用	7
2.2.1 多模态数据集在道路预测中的应用	7
2.2.2 用于交通预测的深度学习框架	7
2.2.3 用于预测的地理空间数据的转化	8
2.2.4 大数据在交通流量预测中的应用	8
3 数据处理和研究方法	8
3.1 数据处理	8
3.1.1 数据来源	8
3.1.2 裁切和重投影	8
3.1.3 数据可视化	8
3.1.4 重新编排数据结构	10
3.2 架构	10
3.2.1 模型结构	10
3.2.2 损失函数	11
3.2.3 训练过程	12
4 实验结果	12
5 讨论与展望	14
5.1 对模型现状的讨论	14
5.2 模型的改进方向	15
5.2.1 提升数据集的丰富度	15
5.2.2 采用 Attention U-Net 结构	15
5.2.3 开发有效的 Connectivity Loss	15
5.3 对该领域未来研究的展望	15
6 结论	15
6.1 创新点	15
6.2 现实意义	16
参考文献	17
致谢	18

1 引入

随着基础设施建设的需求不断增长,当前迫切需要一个能够适应不断变化的环境和社会情况的道路网络建设与扩展的预测框架。传统的道路规划方法主要依赖于耗时耗力的人工调查和人工的综合数据分析,但在现在快速城市化的背景下,这些方法显得越来越不够高效。因此,将地理空间数据和计算机技术结合起来变得尤为重要。近年来,遥感技术的发展和电子地图的广泛应用,使得我们可以获得包括来自政府、组织甚至个人提供的高程数据以及道路和水系数据等的丰富的地理空间数据。这些数据集为利用深度学习技术改变新时代的城市规划方法提供了坚实的基础。

当前,越来越多复杂的机器学习模型的发明,加上日渐增强的算力(如 GPU 的迭代等)以及多样化的训练数据集的激增,为深度学习在多个领域的革命性应用奠定了基础。在地理空间分析领域,深度学习已在解决诸如交通网络识别 [1]、交通情况预测 [2] 等复杂的预测任务中发挥了关键作用。这些进展有力地证明了深度学习技术在地理空间预测中的可行性,从而使得通过机器学习技术赋能道路规划成为一种可能。

在这样的大背景下,本研究采用了以图像分割任务著称的 U-Net 架构 [3],并进一步通过 AdamW 优化器和 IoU Loss 与 Focal Loss [4] 优化,用于预测道路网络建设的可能方案。模型处理了大量的地理空间数据(包括 shapefile 格式的详细河流、道路网络和住宅区位置,以及以 TIFF 格式储存的高程数据,为预测道路网络建设提供了全面且充足的数据基础。为了解决数据中类别不平衡这一关键问题,本研究使用了带有位置权重张量的 Focal Loss,以解决数据集中道路矢量因为像素比例过小而模型很难学习的问题。

该模型的训练和评估过程使用了 60% 训练集、20% 验证集和 20% 测试集的数据划分形式。这样的划分确保了验证和测试框架的稳定,以确保模型在不同地理环境中都能够准确和可泛化地进行预测。本研究的最终目标是利用先进的深度学习技术来提高道路网络预测的准确性和效率,和展示如何有效利用这些技术进步来支持经济增长和战略性的城市规划。

本文结构如下:引言之后的第二部分回顾了与本项目相关的人工智能技术、地理空间数据分析和道路网络预测领域的相关研究;第三部分介绍了我们的实验设置,包括数据处理、模型配置和训练过程;第四部分展示了实验结果并进行解释;第五部分阐述了该预测结果的意义并讨论了当前的局限性和发展方向;最后,第六部分对论文进行了总结,提出了对该领域的贡献以及未来研究的潜在方向。

2 相关研究

深度学习的兴起显著提升了利用地理空间数据预测和分析道路网络及交通流量的能力。本节回顾了该领域的最新进展,重点介绍了与本研究相关的基础理论、研究方法、应用及其成果。

2.1 深度学习




图 1 人工神经网络的一种简单示例

2.1.1 卷积神经网络 (CNN)

卷积神经网络 (CNN) 构成了人工智能图像分析的基石, 尤其是在处理类似网格状数据结构 (如图像) 的应用中尤为重要。卷积神经网络最早由 LeCun 等人于 1998 年提出 [5], 该网络由专门用于特征提取和分类的层构成——包括卷积层、池化层和全连接层。这种架构使其非常适合用于图像和视频识别任务。

2.1.2 U-Net 架构

在卷积神经网络的基础上, Ronneberger、Fischer 和 Brox 于 2015 年提出的 U-Net 架构 [3] 是一个专门用于图像分割的深度学习架构。该架构的“U 形”设计包含一个收缩路径 (用于捕捉信息), 以及一个对称的扩展路径 (用于实现精确的定位)。虽然这个架构在创始之初主要用于医学领域的图像分割和识别, 它在地理空间分析任务中表现也尤为出色, 例如道路网络预测, 因为在本项目中, 从复杂背景中准确地分割出细节特征的信息并精确地确定其位置非常重要。

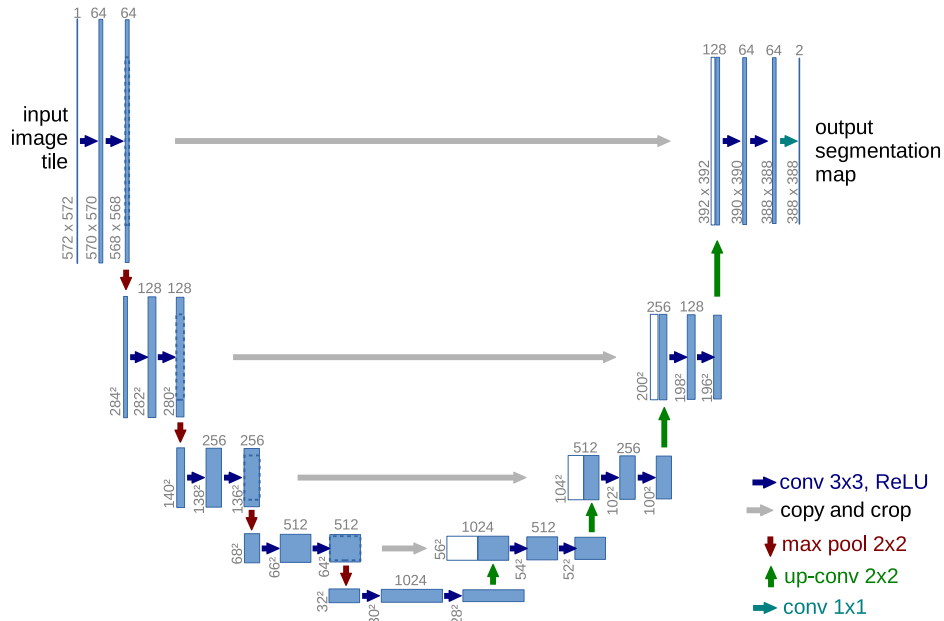


图 2 一种标准 U-Net 架构 (本图来自 [3])

2.1.3 AdamW 优化器

AdamW 优化器 [6] 给诸多深度学习架构（如 U-Net）的优化带来了极大的增强。AdamW 由 Loshchilov 和 Hutter 于 2017 年开发，通过将权重衰减与优化步骤解耦，他们改进了传统的 Adam 优化器。这一调整解决了原始 Adam 优化器中的收敛问题，提升了深度学习模型训练中的泛化能力。在道路预测的神经网络训练中，AdamW 尤为有用，因为在处理多样化数据时，模型的鲁棒性至关重要。

2.1.4 Focal Loss

为了在不平衡数据集上有效训练神经网络，Lin 等人于 2017 年引入了 Focal Loss [4]。这种高级损失函数可以根据分类调整标准的交叉熵损失，增强了模型对难以分类样本的关注。在道路网络预测的背景下，因道路在地理区域中的占比显著较低，Focal Loss 在提高模型的学习能力方面起到了关键作用，确保道路矢量这种微小但极其重要的特征不会被忽视。

2.2 相关应用

2.2.1 多模态数据集在道路预测中的应用

在《AI 驱动的多模态数据道路网络预测》一文中，研究人员探讨了各种数据融合方法在道路网络检测中的有效性 [1]。研究人员结合了卫星影像与 GPS 轨迹数据，并应用了不同的融合技术，如早期融合和后期融合。结果表明，尤其是通过拼接的早期融合在交并比（IoU）指标上优于后期融合，强调了集成方法在提高道路网络预测方面的潜力。该方法与我们的研究方法高度相关，因为它验证了多模态数据集成在提高预测准确性方面的优势。

2.2.2 用于交通预测的深度学习框架

在《基于深度学习的道路交通预测框架》中，提出了一种结合卷积神经网络（CNN）和循环神经网络（RNN）的新型深度学习模型，用于提高交通预测的准确性 [2]。该框架通过 CNN 处理

空间数据，通过 RNN 处理时间动态，专门针对城市交通模式。这种双重方法与我们模型的架构相类似，对于准确的道路预测至关重要。

2.2.3 用于预测的地理空间数据的转化

《地理空间数据与图像的相互转化：一种用于交通预测的深度学习框架》一文中探讨了将地理空间数据转换为类图像格式，以便利用深度学习算法的过程 [7]。该研究解决了将传统地理空间数据预处理为适应神经网络架构的必要步骤，这与我们研究中采用的预处理步骤直接相关。

2.2.4 大数据在交通流量预测中的应用

最后，《基于大数据的交通流量预测》展示了深度学习如何有效处理大规模数据集以预测交通状况 [8]。通过建立能够处理大量数据的深度神经网络架构，该研究为扩展和管理大规模数据输入提供了宝贵的见解，这是我们工作中的关键方面，因为数据量对预测性能有显著影响。

这些研究共同展示了深度学习技术在处理和预测道路和交通数据集中复杂模式方面的强大能力。我们的研究基于这些基础，旨在进一步完善和扩展这些技术的应用，预测现有的道路模式和潜在的扩展方式，以增强区域间的连接性和促进经济增长。

3 数据处理和研究方法

3.1 数据处理

由于我们希望通过一个先进的深度学习模型来预测道路网络的建设，数据集的选择、处理和应用就变得尤为重要。在这个部分，我将介绍这个项目中的几个数据获取途径和处理数据的方法。

3.1.1 数据来源

本项目的数据主要来自多个机构：国家基础地理信息中心、全国地理信息资源目录服务、国家地球系统科学数据中心和地理空间数据云等等。在设计道路时，我们应考虑的因素包括高度、坡度、地质、土壤、气候和居民区等。此外，道路的规划与设计也应重点关注成本和建设难易程度。然而，由于数据和算力的限制，我们仅选择高度（DEM, tiff）、河流（shp）和居民区（shp）作为输入数据，将道路网络作为输出标签。

3.1.2 裁切和重投影

为了提高效率并降低计算成本，我们将数据裁剪一块 1500×1500 像素的区域用于本研究的训练。由于数据来自不同来源，为了确保训练的准确性，我们可以使用 `geopandas` 读取并重新投影河流、居民区、道路等数据为 EPSG:4490 [9] 坐标系。

3.1.3 数据可视化

我们选择宁夏回族自治区作为示例：图 3 就是根据前面提到的地理空间数据生成的图片。我们使用了 `geopandas`、`rasterio` 及 `matplotlib` 来完成这一步。

图中蓝色的线条代表河流，红色的线条表示道路，而这些灰色的点是居民区。

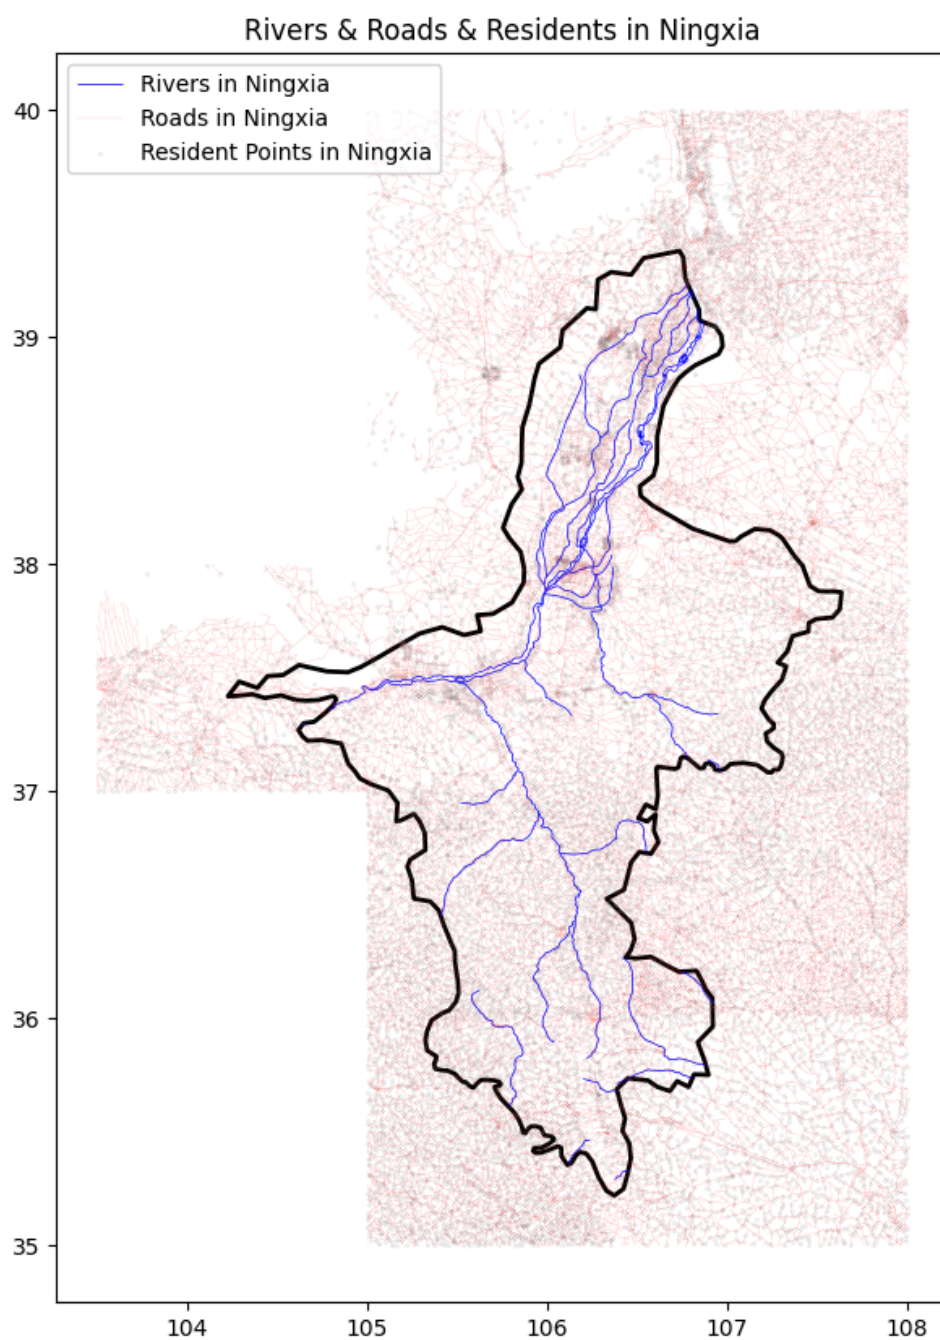


图 3 宁夏回族自治区的地理空间数据

在重新投影坐标系并将所有单个高度文件合并后，我们可以直接使用 `rasterio` 和 `matplotlib` 可视化高度数据。正如之前提到的，为了节省资源，我们将高度数据也裁剪为 1500×1500 像素。

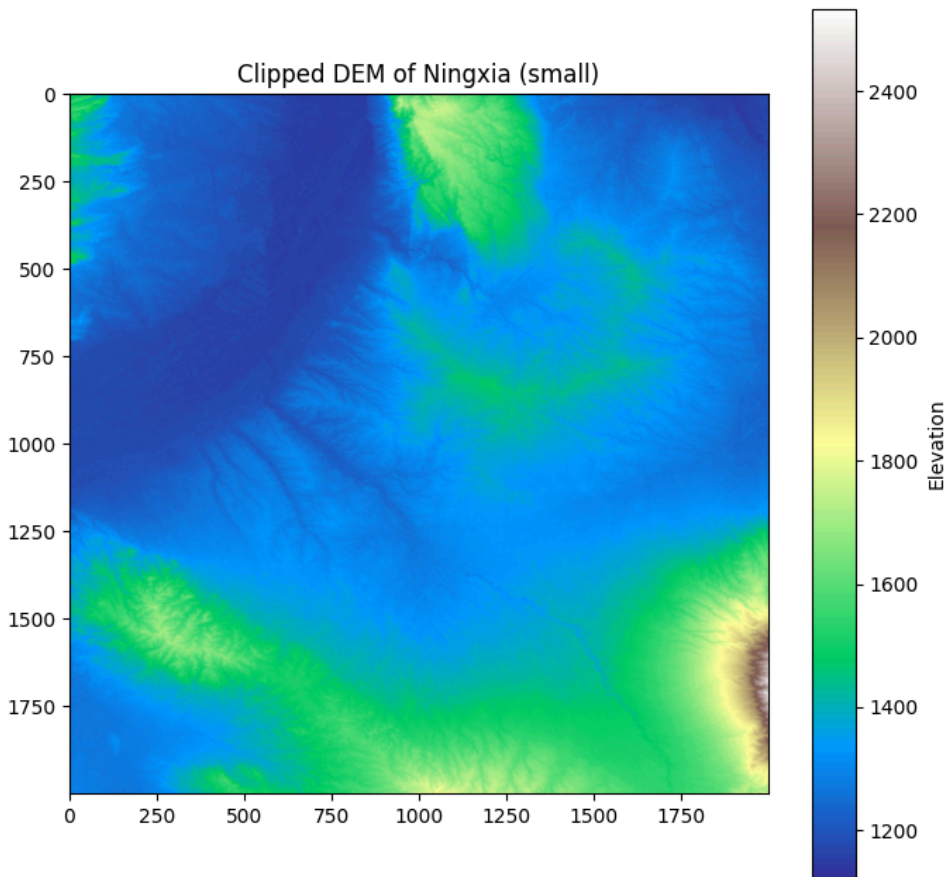


图 4 宁夏回族自治区的高程数据（裁剪后）

3.1.4 重新编排数据结构

为了将这些数据作为输入源一同使用，我们可以将上述所有数据合并起来，该数据为 1500×1500 像素。输入数据将包含 3 个通道，输出将是单通道。

接下来，数据需要分为三个数据加载器：60% 用于训练集，20% 用于验证集，剩下的用于测试集。

3.2 架构

U-Net 架构特别适合处理图像的分割任务。通过将其与其他深度学习技术相结合，我们可以利用这一强大的框架来有效预测道路网络。

3.2.1 模型结构

我们采用 U-Net 架构，这是一种最初为生物医学领域的图像分割设计的卷积神经网络。因为这个模型的两个特殊结构（收缩部分用于捕捉上下文信息，扩展部分用于实现精确定位），它在需要精确定位的情况下非常有效。通过实现多个由两组卷积、批归一化和 ReLU 激活函数组成的双重卷积模块，U-Net 架构在道路分割中的表现尤为突出，因为它能够捕捉到来自高程信息等地理空间数据中不同大小的复杂特征，并将它们精确定位到输出上。

该架构包含多个下采样层，使得在特征数量增加的同时减少数据的空间尺寸，然后再通过跳跃机制将对应的下采样层特征与上采样层的特征联系起来，通过多个上采样层来恢复特征的尺寸。这

种极为特殊的机制保留了在下采样过程中通常会丢失的细节信息，从而确保模型在训练和预测过程中能恢复道路的关键信息。

Define U-Net Architecture:

Input Channels = 3

Output Channels = 1 (Binary mask)

Layers:

- 1 DoubleConv (Input \rightarrow 64 channels)
 - 2 DownSampling (64 \rightarrow 128, 128 \rightarrow 256, 256 \rightarrow 512, 512 \rightarrow 512)
 - 3 UpSampling with skip connections (512 \rightarrow 256 \rightarrow 128 \rightarrow 64)
 - 4 Output Convolution (64 \rightarrow 1, Sigmoid Activation)
-

伪代码 1 U-Net 架构

3.2.2 损失函数

Define FocalLoss:

Parameters: $\alpha = 0.5, \gamma = 3$

Functionality:

Compute BCE Loss with logits

Adjust loss focus based on ground truth relevance and prediction probability

Define ConnectivityLoss:

Parameters: $\alpha = 0.001$

Functionality:

Use a 3×3 convolution kernel to dilate predicted masks

Compute the mean difference between dilated mask and original prediction

伪代码 2 损失函数

为了解决类别不平衡和道路网络预测的难题，我们的模型采用了两种特殊的损失函数：Focal Loss 和 IoU Loss。Focal Loss 旨在调整模型的重点，使其更关注难以分类的实例（因为道路的像素在整体标签中占比极少）。在这种情况下，通过引入调节因子，该损失函数将普通的交叉熵损失转变为一种对难分类样本更为敏感的损失函数。它降低了对已经分类良好的实例的损失权重，使模型更加集中于难处理或预测错误的样本，即覆盖地理区域很小的这些道路数据。在本研究中，我们使用 α -平衡的 Focal Loss 变体：

$$\alpha_t = \begin{cases} \alpha & \text{if label} = 1 \\ 1 - \alpha & \text{else} \end{cases} \quad (1)$$

$$\text{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t). \quad (2)$$

IoU Loss 则通过交并比这样的特殊计算方式，把预测结果和原始图像直接重叠比较，提升了模型在预测道路的边界和走向上的准确性。

Connectivity Loss 进一步增强了模型的预测能力，该损失可以使得预测出的道路网络具有空间连贯性。它对未预测出连续道路的情况施加惩罚，从而提高模型预测出互联道路的可能性。因

此, 这种损失函数组合的最终输出是一个更具连贯性的道路地图, 这让该模型预测的结果在实际的城市设计和交通优化中更加可用。

Function connectivity_loss(mask, alpha=0.001):

Description:

Calculate loss to encourage spatial connectivity in predicted road masks.

Steps:

- 1 Create a 3x3 kernel filled with ones.
- 2 Apply dilation using convolution with padding to maintain dimensions.
- 3 $\text{dilated} = \text{conv2d}(\text{mask}, \text{kernel}, \text{padding}=1)$
- 4 Convert dilated output to binary (values > 0 set to 1).
- 5 Calculate the difference between the dilated mask and original mask.
- 6 Compute the mean of the difference and scale by alpha.
- 7 $\text{CL} = \text{mean}(\text{dilated} - \text{mask}) \times \alpha$

Return:

connectivity_loss: Scalar value representing the loss due to disconnected areas.

伪代码 3 连通性损失

3.2.3 训练过程

我们通过多轮训练优化 U-Net 模型, 在训练时使用了 AdamW 优化器, 这是一种包含权重衰减的 Adam 优化器变体, 用于防止过拟合。模型的训练数据集被分为 60% 的训练集、20% 的验证集和 20% 的测试集, 确保对不同地理空间特征的全面覆盖和泛化能力。

每次训练会将输入数据批量通过网络进行前向传播, 然后利用前面提到的 Focal Loss 和 Connectivity Loss 损失函数计算损失值。通过反向传播调整模型权重, 以最小化这些损失。AdamW 优化器通过结合权重衰减和动量估计来调整学习率, 帮助模型高效收敛。间歇性的验证运行为模型性能提供反馈, 防止过拟合, 并确保模型对新数据的泛化能力。该训练方案不仅确保模型能够学会预测道路, 还确保了其预测结果在道路网络分析和规划中能够具有实际的应用价值。

-
- 1 **For** each epoch:
 - 2 Perform forward pass with U-Net on training data
 - 3 Calculate Focal Loss and Connectivity Loss
 - 4 Backpropagate total loss
 - 5 Update model weights using AdamW optimizer
 - 6 Validate model performance on the validation set
 - 7 Record training and validation losses
-

伪代码 4 训练过程

4 实验结果

本研究主要探讨了在道路网络预测任务中, 采用优化的 U-Net 架构 (结合了 IoU Loss 与 Focal Loss) 对模型性能的影响。实验的目标是评估这种特定配置下模型预测复杂道路网络时的表现。

通过详细的视觉评估和定量分析,我们展示了模型在各种道路场景中的预测结果,以及与基线模型的性能比较。

我们通过采用 IoU Loss 和 Focal Loss 结合的策略,同时提高了模型对小目标的敏感性及其整体预测的空间准确性。IoU Loss 通过优化预测与真实道路区域之间的重叠比率,有效提升了边界定位的准确性。同时,Focal Loss 通过减少易分类样本的权重并增加难分类样本的权重,强化了模型对不平衡数据(即道路与非道路区域)的处理能力。

在 500 个 epoch 的训练过程中,可以观察到训练集和验证集的损失都在缓慢收敛下降,然而由于数据过于复杂,道路建设的影响因素也远不止我们目前采用的这些数据集,它很难进一步学习收敛。同时,模型的训练过程展现出了轻微的过拟合趋势。

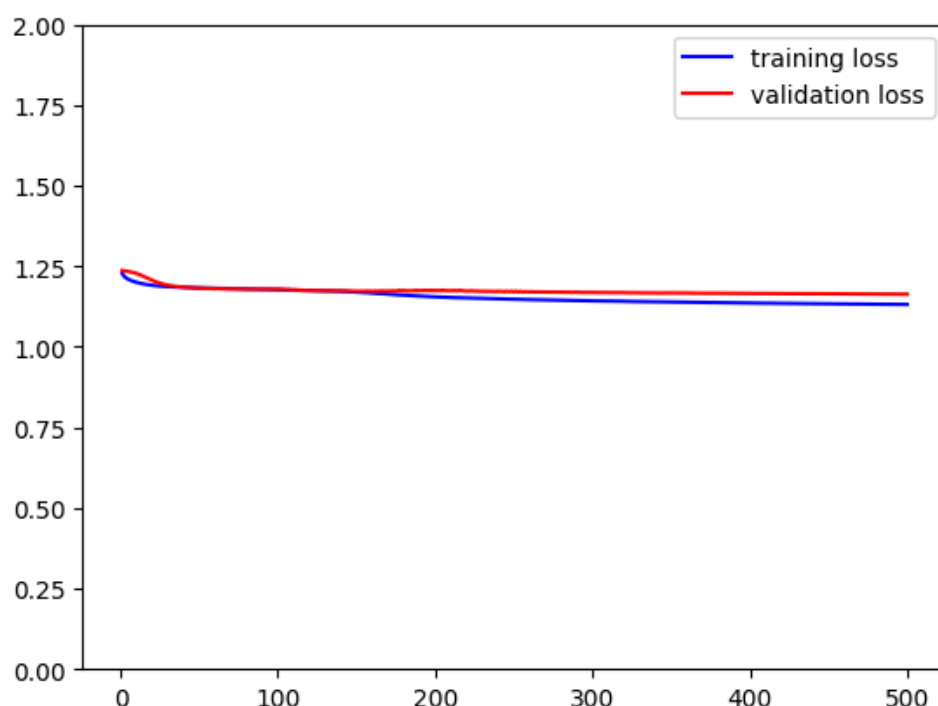


图 5 训练过程的收敛情况

实验结果显示,结合使用这两种损失函数的 U-Net 模型在训练集上的平均 IoU 得分为 0.92,相比仅使用传统二元交叉熵损失的 U-Net 模型 (IoU 得分为 0.6) 有显著提升,这一改进不仅反映在定量指标上,更在视觉效果上得到了验证。在图 6 上能看出,训练集的最终预测结果和真实情况非常相似。普通的卷积神经网络几乎无法对这种输入数据进行学习,因此暂时不做考虑。




图 6 训练集上模型的预测表现

如下图所示, 尽管受到算力和技术的限制, 目前我们无法将预测结果限制成类似于矢量的路网形式, 但经过优化的 U-Net 架构已经相对出色地完成了路网的预测。通过对生成的预测结果进行二次处理与解释, 我们可以得到一张在给定的输入数据集下的较优的路网设计方案。如图 7 所示, 底色的道路网络是现实情况, 上层覆盖的点状是预测的道路走向, 红线则是根据预测情况可以看出的一些主要道路脉络。可以看到, 在一些主要道路上, 该模型预测的结果已经和真实情况相当接近。然而, 道路网络建设的考量因素十分多样, 因而在一些次级道路上模型的预测结果与实际情况有所出入。

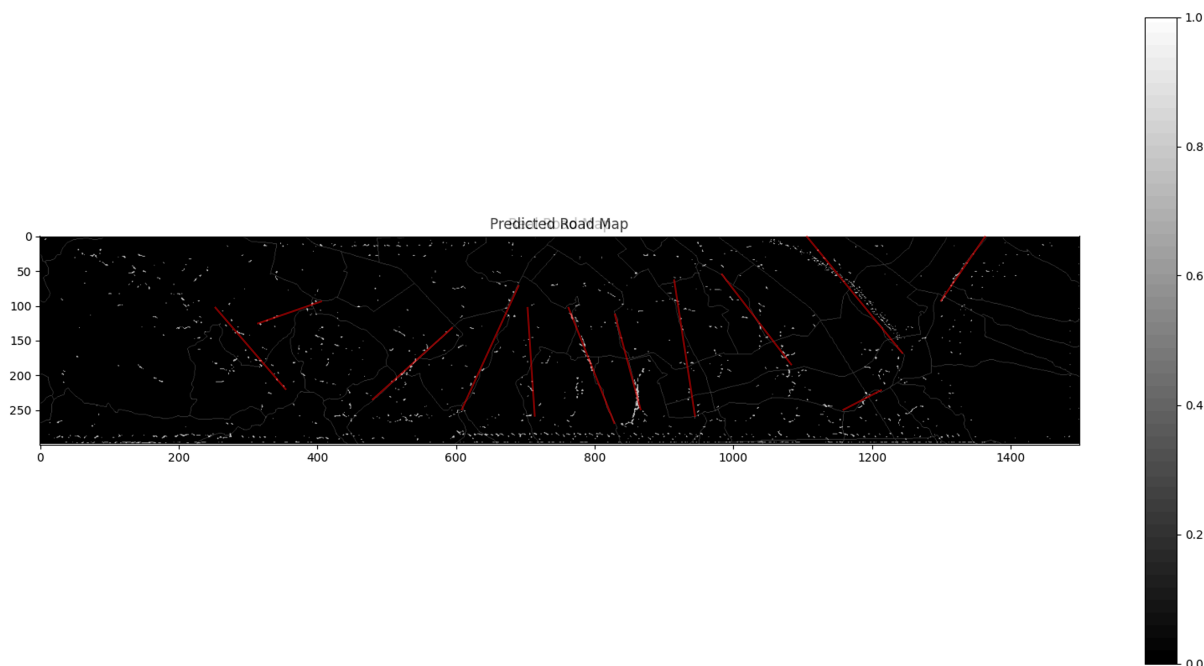


图 7 模型在全新数据上的验证结果

5 讨论与展望

5.1 对模型现状的讨论

在本研究中, 虽然通过优化的 U-Net 架构结合特定的损失函数取得了显著的性能提升, 但在实际应用中路网生成仍面临一些挑战。最主要的问题是影响道路决策的因素极其复杂, 包括但不限于地形、现有基础设施、区域发展规划、环境保护要求等。当前模型主要依赖于有限的数据集, 这些数据集可能没有充分捕捉到所有这些影响因素, 因此在一些复杂场景下的预测准确性还有

待提高。此外，在道路网络的建设中，很难排除人为主观因素的影响，因而通过模型与大量数据预测的道路网络，可能比目前的实际道路网络更加具有可用性。

道路网络的预测不仅需要识别道路本身，还需要理解道路如何在各种物理和社会环境中布局。尽管当前模型已经在处理视觉数据方面表现出色，但由于缺乏对更广泛环境因素的理解，其在未知或变化环境中的适应能力还存在限制。这对数据集的设计和采集提出了更高的要求。

5.2 模型的改进方向

5.2.1 提升数据集的丰富度

为了提升模型的泛化能力和预测准确性，未来的工作应集中于扩展和丰富训练数据集。可以通过整合更多类型的数据，如卫星图像、地质数据、土地使用数据以及城市规划资料，来提供更全面的视角支持道路预测模型。此外，增加数据的地理和环境多样性也是必要的，这将帮助模型学习在不同环境下道路如何被设计和建造。

5.2.2 采用 Attention U-Net 结构

考虑到道路网络的空间特征和上下文信息的重要性，在当前的 U-Net 架构中引入注意力门机制是一大改进方向。Attention U-Net 能够更有效地聚焦于图像中关键的信息区域，对于复杂道路结构的识别和重建，尤其是在高度杂乱的背景中，这种方法可能提供更为准确的预测结果。

5.2.3 开发有效的 Connectivity Loss

为确保生成的路网在视觉上的连续性和实用性，在本模型中整合一个有效的 Connectivity Loss 是关键。这种损失函数应专注于增强预测道路之间的连接性，同时避免过度膨胀和不自然的道路形态。通过结合条件性膨胀策略和图像后处理技术，这种新的损失函数将进一步优化道路的生成质量，使其在实际应用中更为可靠。

5.3 对该领域未来研究的展望

道路网络预测是一个极具挑战性的领域，它在城市规划和地理信息系统中具有广泛的应用前景。随着机器学习技术的进步和计算资源的增加，预计未来的研究将能够处理更大规模的数据集，应用更复杂的模型，实现更精准的预测。

未来的研究还应该探索如何有效融合多源数据和利用先进的机器学习技术来理解和预测复杂的城市环境中的路网布局。此外，研究如何将模型的预测结果与实际的城市发展和交通管理系统集成，也是一个值得关注的方向。这不仅能够提高道路网络预测的实际应用价值，也有助于推动智能交通和智慧城市建设的发展。

总之，随着数据集的改善和计算能力的提高，结合跨学科的研究方法，未来有望开发出更智能、更精确且更具适应性的道路网络预测系统。

6 结论

本研究通过优化 U-Net 架构并将其与 IoU 损失与 Focal 损失相结合，显著提升了神经网络在道路网络预测上的准确性。这些优化方式在处理复杂道路网络预测任务中带来了显著的提升，尤其是在城市环境和复杂地形中的表现。

6.1 创新点

1. 损失函数的结合使用:本研究把 IoU Loss 与 Focal Loss 结合应用于道路网络预测。IoU Loss 优化了模型在预测道路边界方面的表现,通过精确计算预测区域与实际区域之间的重叠度,它显著提高了模型边界定位的准确性。Focal Loss 则专注于改善模型对不平衡数据的处理,通过调整对易分类和难分类样本的关注度,强化了模型对道路特征的识别能力。这种损失函数的结合有效地提升了模型对复杂道路结构的预测能力,特别是在复杂场景中表现出色。
2. 优化的 U-Net 架构:我们对传统的 U-Net 架构进行了深入的优化,特别是在特征提取和信息传递机制方面进行了创新调整,以适应道路网络预测的特殊需求。这种优化包括增强了编码器和解码器的能力,使其能够捕捉更细致的道路信息,并通过改进跳跃连接来保持高分辨率的特征传递,从而使得模型在预测细小和断续的道路时更为准确和可靠。这些改进使得模型不仅能处理广阔的道路网络,还能精确地识别和预测城市中常见的狭窄和复杂道路。

6.2 现实意义

本研究开辟了深度学习模型在道路网络预测方面的应用,并为该领域的研究提供了新的方向。通过这些创新,深度学习模型在城市规划和地理信息系统中的应用前景被极大地扩展。未来的研究将聚焦于进一步丰富数据集,引入更多类型的环境数据,并探索结合更先进的神经网络架构,如引入注意力门机制的 U-Net,以进一步增强模型的预测能力和泛化能力。此外,也可以考虑将这些技术与实时数据流集成的可能性,这将会是推动智慧城市发展的重要方向。

总而言之,本研究不仅在学术上取得了创新的成果,而且在实际应用中展现了巨大的潜力和价值,为未来智能道路预测技术的广泛应用提供了坚实的基础。

参考文献

- [1] N. E. Gengec, E. Tari, 和 U. Bagci, 《AI powered road network prediction with fused low-resolution satellite imagery and GPS trajectory》, *Earth Science Informatics*, 卷 17, 期 2, 2024, doi: 10.1007/s12145-023-01201-6.
- [2] R. Benabdallah Benarmas 和 K. Beghdad Bey, 《A deep learning-based framework for road traffic prediction》, *The Journal of Supercomputing*, 卷 80, 期 5, 页 6891–6916, 10 月 2023, doi: 10.1007/s11227-023-05718-x.
- [3] O. Ronneberger, P. Fischer, 和 T. Brox, 《U-Net: Convolutional Networks for Biomedical Image Segmentation》, 2015, [在线]. 载于: <https://arxiv.org/abs/1505.04597>
- [4] T.-Y. Lin, P. Goyal, R. Girshick, K. He, 和 P. Dollár, 《Focal Loss for Dense Object Detection》, 2018, [在线]. 载于: <https://arxiv.org/abs/1708.02002>
- [5] Y. Lecun, L. Bottou, Y. Bengio, 和 P. Haffner, 《Gradient-based learning applied to document recognition》, *Proceedings of the IEEE*, 卷 86, 期 11, 页 2278–2324, 1998, doi: 10.1109/5.726791.
- [6] I. Loshchilov 和 F. Hutter, 《Decoupled Weight Decay Regularization》, 2019, [在线]. 载于: <https://arxiv.org/abs/1711.05101>
- [7] W. Jiang 和 L. Zhang, 《Geospatial data to images: A deep-learning framework for traffic forecasting》, *Tsinghua Science and Technology*, 卷 24, 期 1, 页 52–64, 2019, doi: 10.26599/TST.2018.9010033.
- [8] Y. Lv, Y. Duan, W. Kang, Z. Li, 和 F.-Y. Wang, 《Traffic Flow Prediction With Big Data: A Deep Learning Approach》, *IEEE Transactions on Intelligent Transportation Systems*, 卷 16, 期 2, 页 865–873, 2015, doi: 10.1109/TITS.2014.2345663.
- [9] 《China Geodetic Coordinate System 2000 - EPSG:4490》. [在线]. 载于: <https://epsg.io/4490>

致谢